

Análisis Topológico de Datos

* <https://github.com/joperca/TDA-Fall2025>

Conjuntos de Datos (X, d_X) :

a) Un conjunto X (finito o no)

Ejemplos: Vectores, imágenes, sonidos, videos, documentos (texto), moléculas, etc.

b) Una función (distancia)

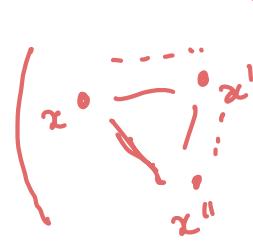
$d_X : X \times X \rightarrow [0, \infty]$ tal que

i) $d_X(x, x) = 0$ para todo x en X ($\forall x \in X$)

ii) $d_X(x, x') = d_X(x', x)$ $\forall x, x' \in X$ (simétrica)

Si además

iii) $d_X(x, x'') \leq d_X(x, x') + d_X(x', x'')$ $\forall x, x', x'' \in X$


desigualdad triangular

diremos que d_X es una pseudo métrica extendida
 $(d_X(x, x') = 0, x \neq x')$ $(d_X(x, x') = \infty)$

iv) Si i) - ii) y $d_X(x, x') < \infty \quad \forall x, x' \in X$,
 d_X es una pseudo métrica

v) Si i) - iv) y $d_X(x, x') = 0$ solo si $x = x'$,
entonces d_X es una métrica y (X, d_X)
un espacio métrico.

Ejemplos

Distancias entre vectores:

1) $X = \mathbb{R}^n$ y $d_2(x, y) = \|x - y\|_2$

donde $\|x_1, \dots, x_n\|_2 = \left(x_1^2 + \dots + x_n^2 \right)^{1/2}$.

Por tanto $d_2(x, y) = \left((x_1 - y_1)^2 + \dots + (x_n - y_n)^2 \right)^{1/2}$.

Ejercicio:

a) Muestra que $(\mathbb{R}^n, d_2(\cdot, \cdot))$ es un espacio métrico.

b) Sea $p \in \mathbb{N} = \{1, 2, 3, \dots\}$ y para $x, y \in \mathbb{R}^n$ define

$$d_p(x, y) = \|x - y\|_p \leftarrow p\text{-norma}$$

$$= \left(|x_1 - y_1|^p + \dots + |x_n - y_n|^p \right)^{1/p}$$

Muestra que (\mathbb{R}^n, d_p) es un espacio métrico.

c) Para $(x_1, \dots, x_n) \in \mathbb{R}^n$ sea

$$\| (x_1, \dots, x_n) \|_{\infty} = \max \left\{ |x_1|, |x_2|, \dots, |x_n| \right\}$$

\nearrow
norma del supremo

y defina $d_{\infty}(x, y) = \|x - y\|_{\infty}$

$$= \max \{ |x_1 - y_1|, \dots, |x_n - y_n| \}$$

Muestra que $(\mathbb{R}^n, d_{\infty})$ es un espacio métrico,

y que $\lim_{p \rightarrow \infty} d_p(x, y) = d_{\infty}(x, y)$ si $x, y \in \mathbb{R}^n$

$d_p(\cdot, \cdot) :$

- $p = 1$: Distancia Manhattan (del taxista)

- $p = 2$: Distancia Euclídea

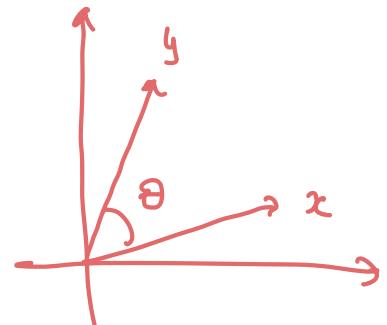
- $p = \infty$: Distancia del supremo.

2) Para $x, y \in \mathbb{R}^n$ sea $x \cdot y = x_1 y_1 + x_2 y_2 + \dots + x_n y_n$
 ↑ producto punto (interno)

Si $x, y \neq \vec{0}$, defina:

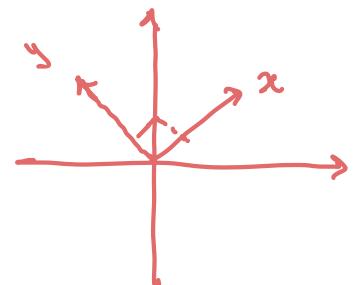
$$d_{\cos}(x, y) = \frac{x \cdot y}{\|x\|_2 \cdot \|y\|_2} = \cos \theta$$

↑ distancia del coseno.



Nota: $d_{\cos}(\cdot, \cdot)$ no es una métrica

i) $x = (1, 1)$, $y = (-1, 1)$



$$\|x\|_2 = \|y\|_2 = \sqrt{2}$$

$$x \cdot y = 1 \cdot (-1) + 1 \cdot 1 = 0$$

$$d_{\cos}((1, 1), (-1, 1)) = \frac{0}{\sqrt{2} \cdot \sqrt{2}} = 0.$$

ii) Ejercicio: Muestra que $d_{\cos}(\cdot, \cdot)$ no satisface la desigualdad triangular.

Nota: $d_{\cos}(\cdot, \cdot)$ es útil para comparar textos.

Diccionario :	palabra 1, palabra 2, ..., palabra n
Texto 1	$(t_{11}, t_{12}, \dots, t_{1n}) = t_1$
Texto i	$(t_{i1}, t_{i2}, \dots, t_{in}) = t_i$
Texto m	$(t_{m1}, t_{m2}, \dots, t_{mn}) = t_m$

$t_{ik} = \#$ de veces que la palabra k aparece en el Texto i

$$\text{similaridad}(\text{Texto } i, \text{Texto } j) = d_{\text{cos}}(t_i, t_j)$$

Visualización y Reducción de Dimensión

Problema: Dado (X, d_X) , $X = \{x_1, \dots, x_L\}$, encontrar $n \in \mathbb{N}$ (usualmente $1 \leq n \leq 5$)

$$y \in Y = \{y_1, \dots, y_L\} \subseteq \mathbb{R}^n \text{ tal que}$$

$$d_X(x_i, x_j) \approx \|y_i - y_j\|_2, \quad 1 \leq i, j \leq L$$

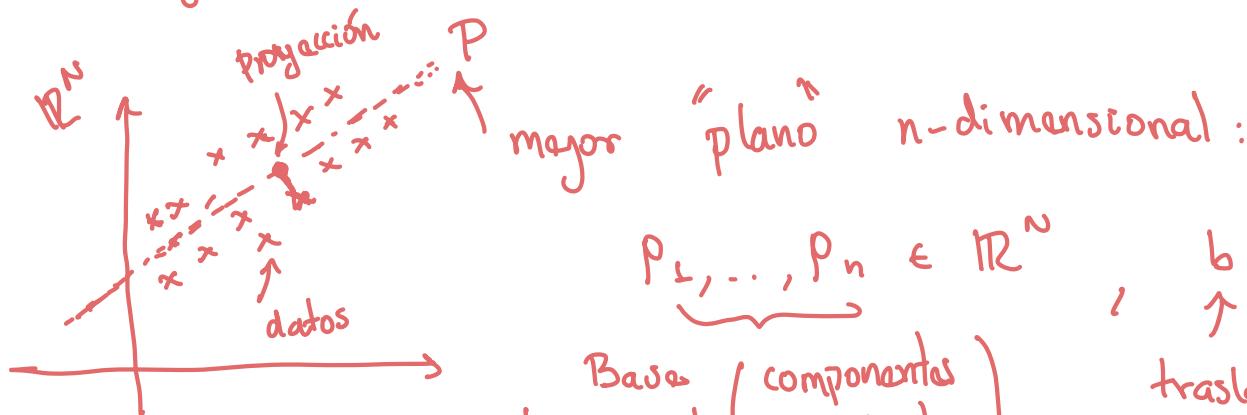
Analisis de Componentes Principales (PCA)

En el caso $X = \{x_1, \dots, x_L\} \subseteq \mathbb{R}^N$ ($N \gg 1$)

$$d_X(x_i, x_j) = \|x_i - x_j\|_2$$

\uparrow
mucho mas
grande que

idea: "regresion lineal" (mínimos cuadrados)



$$P = \{b + \lambda_1 P_1 + \dots + \lambda_n P_n \mid \lambda_i \in \mathbb{R}, 1 \leq i \leq n\}$$

$\text{proy}_P : \mathbb{R}^N \rightarrow P$ proyección orthogonal

$$y_L = \text{proy}_P(x_L), \quad 1 \leq L \leq L$$

\uparrow
Datos

proyección

$$(x_{11}, x_{12}, \dots, x_{1n}) \in \mathbb{R}^n$$

$$(x_{21}, x_{22}, \dots, x_{2n}) \in \mathbb{R}^n$$