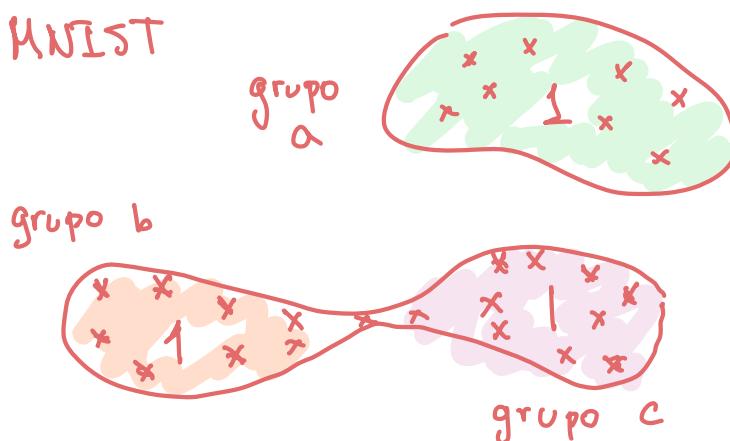


Ayer:

conjunto \downarrow distancia
 * Datos (X, d_X)

* MNIST



Topología	Ciencia de datos
Componentes	clusters
arco-conexas	(agrupamientos)

Hoy:

- * Componentes arco-conexas

- * D-homología

- * Clustering (agrupamiento)

— II —

Daf: Un grafo (no dirigido) es un par

$G = (V, E)$ donde

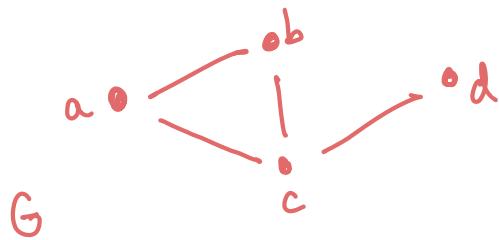
$V \leftarrow$ conjunto de vértices

$E \subseteq \{ \{v, v'\} \mid v, v' \in V, v \neq v' \}$

\nwarrow conjunto de aristas

Ejemplos

1)



$$V = \{a, b, c, d\}$$

$$E = \{\{a, b\}, \{a, c\}, \{c, d\}\}$$

2) Sea (X, d_X) un conjunto de datos y $\varepsilon > 0$.

$$\text{Sea } E_\varepsilon(x) = \left\{ \{x, x'\} \subseteq X \mid 0 < d_X(x, x') < \varepsilon \right\}$$

y defina

$$G_\varepsilon(x, d_X) = (X, E_\varepsilon(x))$$

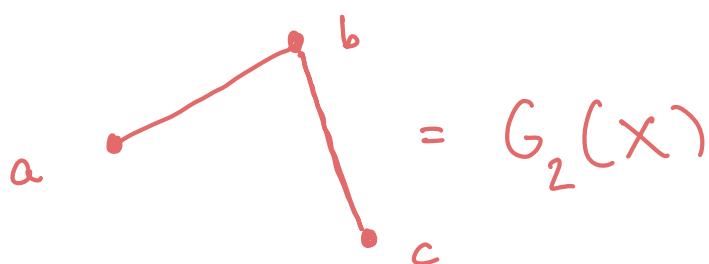
↑
verticos
↑
aristas

grado de
 ε -vecindad

e.g. $X = \{a, b, c\}$,

d_X	a	b	c
a	0	1	2
b	1	0	1.5
c	2	1.5	0

, $\varepsilon = 2$



3) Sea (X, d_X) un espacio métrico finito, y $1 \leq k < \#(X)$. Para $x \in X$ sea

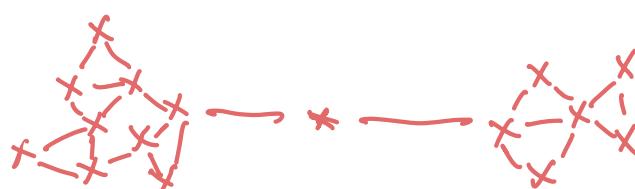
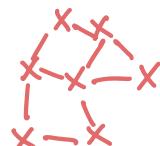
$$E_k(x) = \left\{ \{x, x'\} \subseteq X \mid \begin{array}{l} x' \neq x \text{ es uno de los} \\ k \text{ vecinos más cercanos} \\ \text{a } x \end{array} \right\}$$

$$G_k(X, d_X) = (X, E_k(x))$$

↑ ↑ ↑
 grafo de vértices aristas
 k - vecinos
 más cercanos

E.g. $k=2$

X



Def: Un camino en un grafo $G = (V, E)$ es una sucesión finita

$$\Gamma = (\{v_0, v_1\}, \{v_1, v_2\}, \dots, \{v_{n-1}, v_n\})$$

de aristas $\{v_j, v_{j+1}\} \in E$, $j = 0, \dots, n-1$.

$v_0 = i(\Gamma) \leftarrow$ inicio, $v_n = f(\Gamma) \leftarrow$ final.

Def: Dado un grafo $G = (V, E)$, diremos que dos vértices $v, v' \in V$ están conectados por caminos ($v \sim v'$) si $v = v'$, o $v \neq v'$ y existe un camino I con $v = i(I)$ y $v' = f(I)$.

Prop: \sim es una relación de equivalencia en V .

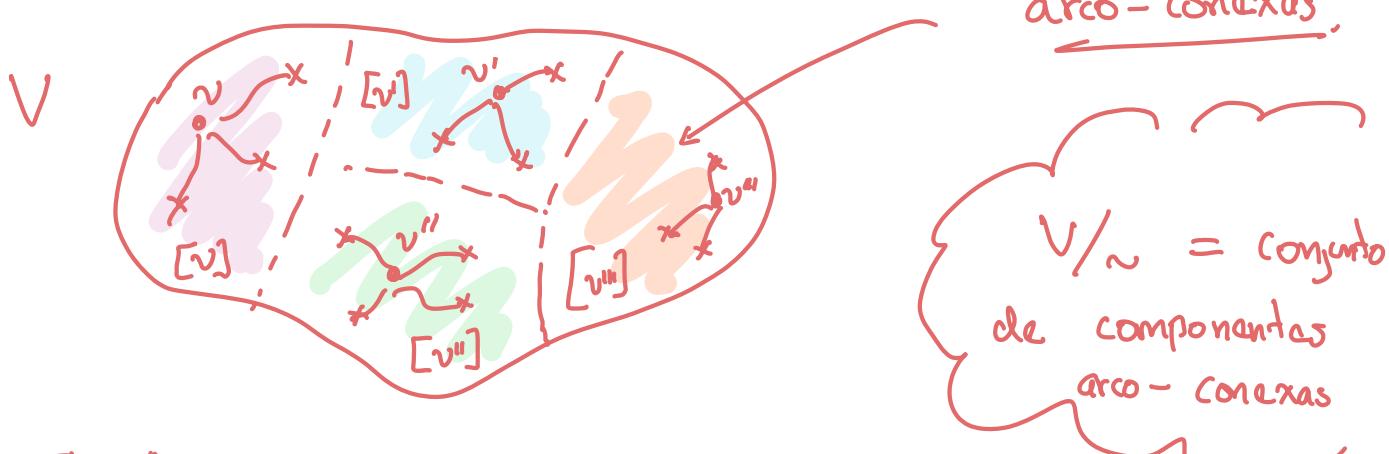
→ reflexiva: $v \sim v$

→ simétrica: si $v \sim v'$ entonces $v' \sim v$

→ transitiva: si $v \sim v'$ y $v' \sim v''$ entonces $v \sim v''$

Note: \sim partitiona V en clases (disjuntas)

de equivalencia, llamadas componentes



Clustering Topológico:

(X, d_X)
datos

\Rightarrow
 $G_\alpha(X, d_X)$
grafo de proximidad

\Rightarrow
 X/\sim
Componentes arco-conexas

Algoritmos: $G = (V, E)$ finito con $n_E = \#(E)$.

El algoritmo de Kruskal (para encontrar maximum spanning trees con union-find) toma $\Theta(n_E \cdot \log(n_E))$ tiempo.

Versión algebraica: O-homología

Sea $(\mathbb{F}, +, *)$ un campo (e.g. $\mathbb{R}, \mathbb{Q}, \mathbb{C}$, o $\mathbb{Z}_p = \mathbb{Z}/p\mathbb{Z}$ para $p \in \mathbb{N}$ primo) y para $G = (V, E)$

sean: $C_0(G; \mathbb{F}) = \text{Span}_{\mathbb{F}}(V)$

↑
O-cadenas
(vertices)

$$= \left\{ \lambda_1 v_1 + \dots + \lambda_n v_n \mid \begin{array}{l} n \in \mathbb{N}, \lambda_i \in \mathbb{F} \\ v_i \in V, 1 \leq i \leq n \end{array} \right\}$$

= Espacio vectorial sobre \mathbb{F} con base (i.e., generado por) V .

$C_1(G; \mathbb{F}) = \text{Span}_{\mathbb{F}}(E)$

↑
1-cadenas.
(aristas)

$$= \left\{ \beta_1 e_1 + \dots + \beta_m e_m \mid \begin{array}{l} m \in \mathbb{N}, \beta_j \in \mathbb{F} \\ e_j \in E, 1 \leq j \leq m \end{array} \right\}$$

= Espacio vectorial sobre \mathbb{F} generado por E .

Fije un buen orden \leq en V (todo subconjunto no vacío tiene un elemento mínimo = Teorema de Zermelo \Leftrightarrow Axioma de elección)

$$\Rightarrow e \in E \Rightarrow \begin{array}{c} e \\ i(e) \\ f(e) \end{array} \quad e = \{i(e), f(e)\} \subseteq V$$

$i(e) \leq f(e)$

Defina la frontera de e como

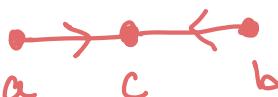
$$\partial(e) = f(e) - i(e) \in C_0(G; \mathbb{F})$$

Como E es una base para $C_1(G; \mathbb{F})$, entonces ∂ define una única transformación lineal

$$\partial : C_1(G; \mathbb{F}) \longrightarrow C_0(G; \mathbb{F})$$

Dada por:

$$\begin{aligned} \partial \left(\sum_{j=1}^m \beta_j \cdot e_j \right) &= \sum_{j=1}^m \beta_j \cdot \partial(e_j) = \sum_{j=1}^m \beta_j \cdot (f(e_j) - i(e_j)) \\ &= \sum_{j=1}^m \beta_j \cdot f(e_j) - \sum_{j=1}^m \beta_j \cdot i(e_j) \end{aligned}$$

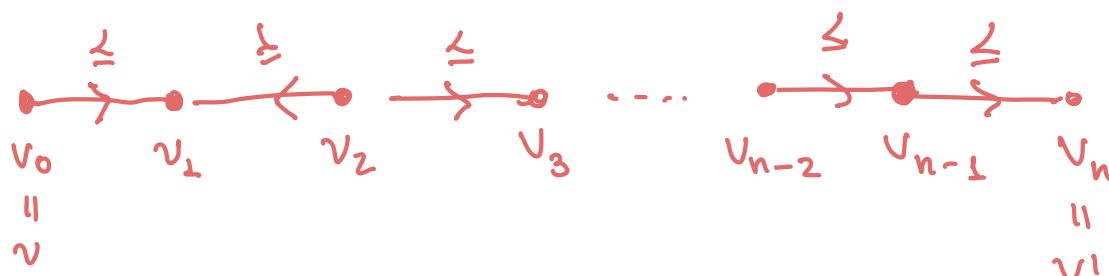
Ejemplo:  G , $\partial(\{a, c\} - \{b, c\}) = b - a$

Teorema: Sea $G = (V, E)$ un grafo y $v, v' \in V$.

$v \sim v'$ (conectados por caminos) si y solo si
 $v' - v \in \text{img}(\partial)$.

Prueba: (\Rightarrow) Si $v \sim v'$, entonces existe
 un camino $\Gamma = (\{v_0, v_1\}, \{v_1, v_2\}, \dots, \{v_{n-1}, v_n\})$

en G con $v = v_0 = i(\Gamma)$ y $v' = v_n = f(\Gamma)$.



Sea

$$\gamma_j = \begin{cases} 1 & \text{si } v_{j-1} \leq v_j \\ -1 & \text{si } v_{j-1} \geq v_j \end{cases}$$

note que $\partial(\gamma_j \{v_{j-1}, v_j\}) = v_j - v_{j-1}$

$$j = 1, \dots, n$$

$$\text{Si } \gamma = \sum_{j=1}^n s_j \cdot \{v_{j-1}, v_j\} \in C_1(G; \mathbb{F}),$$

entonces

$$\begin{aligned} \text{img}(\partial) \ni \partial(\gamma) &= \partial \left(\sum_{j=1}^n s_j \cdot \{v_{j-1}, v_j\} \right) \\ &= \sum_{j=1}^n \partial(s_j \{v_{j-1}, v_j\}) \\ &= \sum_{j=1}^n v_j - v_{j-1} = v_n - v_0 \\ &\qquad\qquad\qquad = v' - v \end{aligned}$$

$$\Rightarrow v' - v \in \text{img}(\partial).$$

$$(\Leftarrow) \text{ Si } v' - v = \partial \left(\sum_{j=1}^m \beta_j e_j \right), \quad \begin{array}{l} \beta_j \in \mathbb{F} \\ e_j \in E \end{array}$$

entonces uno puede utilizar algunos de los e_j 's

para construir un camino Γ de v a v'

(ver: Munkres, Elements of Algebraic Topology, Thm 7.1)

Corolario: El espacio vectorial cociente

$$H_0(G; \mathbb{F}) := C_0(G; \mathbb{F}) / \text{img}(\partial)$$

base = vértices de G
diferen por
un camino

↑
0-homología
de G con coeficientes
en \mathbb{F}

tiene dimensión

$$\#(V/\sim) = \# \text{ de componentes}$$

arco-conexas de G .